

Classificação de Gênero Musical com MLP e CNN: Uma Comparação no Dataset GTZAN

Breno Back dos Santos Miranda da Silva (Matrícula: 190063980)

Leonardo Pereira Côrtes (Matrícula: 200030582)

Mariana Soares Oliveira (Matrícula: 231013663)

Matheus de Souza Fernandes (Matrícula: 231025243)

Universidade de Brasília

Abstract—This paper presents a comparison between...

Keywords—Music genre classification, GTZAN, MLP, CNN, MFCC, spectrogram.

Resumo—Este artigo apresenta uma comparação entre...

Palavras-chave—Classificação de gênero musical, GTZAN, MLP, CNN, MFCC, espectrograma.

I. INTRODUÇÃO

A classificação automática de gênero musical é uma tarefa cada vez mais importante devido ao crescimento das plataformas de *streaming* e à necessidade de organizar grandes catálogos de áudio. No entanto, classificar músicas por gênero é um desafio prático, pois os estilos musicais são conceitos bastante subjetivos. Músicas de um mesmo estilo podem soar de formas muito diferentes (devido à alta variabilidade intra-gênero), e gêneros distintos podem compartilhar características acústicas parecidas, dificultando a separação das categorias.

O objetivo deste artigo é comparar o desempenho de duas redes neurais diferentes na classificação de gêneros musicais, utilizando o dataset GTZAN [?]. A primeira abordagem utiliza dados tabulares com as características acústicas do áudio para treinar um *Multilayer Perceptron* (MLP). Já a segunda abordagem utiliza os espectrogramas das músicas, tratando o problema como uma tarefa de visão computacional para treinar uma Rede Neural Convolucional (CNN). Com isso, o trabalho busca avaliar qual formato de entrada e arquitetura apresenta os melhores resultados.

O artigo está organizado da seguinte forma: a Seção II apresenta trabalhos relacionados na área; a Seção III descreve o dataset e os métodos de pré-processamento aplicados; a Seção IV detalha a construção dos modelos MLP e CNN; a Seção V mostra os resultados alcançados; a Seção VI discute o desempenho das abordagens e, por fim, a Seção VII finaliza o artigo com a conclusão.

II. TRABALHOS RELACIONADOS

Diversos estudos exploraram a classificação de gênero musical utilizando diferentes representações de entrada. Para a extração de características acústicas tabulares, os coeficientes MFCC (*Mel-Frequency Cepstral Coefficients*) são amplamente consolidados na literatura de processamento de áudio. Logan [?] demonstrou a eficácia dos MFCCs para a modelagem

musical, destacando sua capacidade de capturar a envoltória espectral do som de forma análoga à percepção auditiva humana, tornando-se o padrão de entrada para redes como o *Multilayer Perceptron* (MLP) em tarefas de áudio.

Na abordagem visual, Costa et al. [?] avaliaram redes neurais convolucionais aplicadas a espectrogramas para classificação musical, demonstrando que tratar o áudio como uma imagem e delegar a extração de características à própria rede pode superar descritores acústicos projetados manualmente. O presente trabalho segue essa linha na abordagem CNN e a contrasta diretamente com um modelo tabular (MLP) treinado sobre descritores MFCC.

III. DATASET E PRÉ-PROCESSAMENTO

A. GTZAN Dataset

Os experimentos deste projeto utilizaram o dataset GTZAN [?], um dos bancos de dados mais conhecidos para pesquisas em processamento de áudio. O conjunto contém 1000 clipes, distribuídos igualmente em 10 gêneros musicais (100 amostras por categoria). Cada arquivo de áudio possui 30 segundos de duração.

B. Divisão dos Dados

Ao utilizar o GTZAN, é essencial tratar o alto risco de *data leakage* (vazamento de dados). Isso ocorre porque o dataset possui diversos clipes que foram recortados de trechos diferentes de uma mesma música. Se a divisão dos dados em subconjuntos fosse totalmente aleatória, o modelo poderia ver uma parte da música no treinamento e outra parte da mesma música no teste. Isso faria a acurácia saltar artificialmente para mais de 90%, pois a rede estaria memorizando as músicas em vez de aprender os padrões gerais de cada gênero.

Para evitar esse problema, foi realizado um *split* estratificado mantendo uma semente aleatória fixa (`random_state=42`). Os dados foram divididos seguindo a proporção de 70% para treinamento, 15% para validação e 15% para teste.

C. Pré-processamento Tabular

Para alimentar a rede MLP, foram utilizadas *features* previamente extraídas, com foco nos coeficientes MFCCs (*Mel-Frequency Cepstral Coefficients*). Colunas que não agregam

informação para a classificação computacional, como o nome do arquivo e a duração da faixa, foram removidas.

A normalização dos valores foi feita com a função `StandardScaler`. Para garantir que dados do futuro não influenciassem o aprendizado, o escalonador foi ajustado (`fit`) exclusivamente com o conjunto de treino. Só então a transformação foi aplicada para colocar os conjuntos de validação e teste na mesma escala.

D. Pré-processamento de Imagens

Na abordagem com a CNN, os dados de entrada foram os espectrogramas das músicas originais. Para adequar as imagens ao modelo e otimizar o processamento, elas foram convertidas para escala de cinza e redimensionadas para a resolução de 128×128 pixels.

Os valores dos pixels foram normalizados, sendo divididos por 255.0 para que ficassem no intervalo entre 0 e 1. Por fim, para que a comparação entre os dois modelos fosse cientificamente justa, a separação das imagens em treino, validação e teste utilizou os exatos mesmos índices gerados no `split` dos dados tabulares.

IV. METODOLOGIA

A. Modelo Tabular - MLP

A abordagem tabular foi desenvolvida utilizando a biblioteca `scikit-learn`. A arquitetura do *Multilayer Perceptron* (MLP) baseou-se diretamente nas *features* MFCCs extraídas. Para encontrar a arquitetura ideal e mitigar os efeitos de *overfitting*, foi implementada uma busca de hiperparâmetros utilizando a técnica `RandomizedSearchCV` com validação cruzada estratificada (`cv=5`) e 20 iterações. O espaço de busca abrangeu variações na topologia da rede (de uma a três camadas ocultas), funções de ativação (`ReLU` e `Tanh`), taxa de aprendizado inicial e o fator de regularização L2 (*alpha*).

A configuração de melhor desempenho consistiu em uma arquitetura enxuta, possuindo uma única camada oculta com 128 neurônios, função de ativação `ReLU`, taxa de aprendizado inicial de 0,01 e um termo de regularização *alpha* de 0,0001, operando sob o otimizador Adam. Além da simplicidade arquitetural, a técnica de *Early Stopping* foi fundamental: o treinamento foi configurado para ser interrompido caso a perda (*loss*) no conjunto de validação não apresentasse melhora por 20 épocas consecutivas. Essa estratégia demonstrou-se altamente eficaz para interromper o aprendizado antes que a rede passasse a memorizar os dados de treino, favorecendo a generalização.

B. Modelo Visual - CNN

A rede convolucional foi implementada em Keras e recebe como entrada os espectrogramas em escala de cinza de dimensão $128 \times 128 \times 1$. A arquitetura é composta por três blocos convolucionais seguidos por uma camada `Conv2D` com filtros 3×3 e ativação `ReLU` (com `padding` do tipo `same`, que preserva a dimensão).

Cada bloco convolucional contém uma camada `Conv2D` com filtros 3×3 e ativação `ReLU` (com `padding` do tipo `same`, que preserva a dimensão).

`2eDropout` de 0,25. O número de filtros cresce a cada bloco (32, 64 e 128), preservando a dimensão espacial. Os primeiros blocos, após a extração das texturas locais do espectrograma, nos primeiros blocos, após a extração das

Após os blocos convolucionais, os mapas de características são achatados (`Flatten`) e processados por uma camada `Dense` de 256 neurônios com ativação `ReLU`, um `Dropout` mais agressivo de 0,5 e, por fim, uma camada `Dense` de 10 neurônios com ativação *softmax*, que produz a distribuição de probabilidade sobre os gêneros.

O treinamento utilizou o otimizador Adam (*learning rate* inicial de 10^{-3}) e a função de perda *sparse categorical crossentropy*, com *batches* de 32 amostras por até 50 épocas. Dois *callbacks* controlaram o processo: o *EarlyStopping* (monitorando a acurácia de validação, com paciência de 10 épocas e restauração dos melhores pesos), para conter o *overfitting*, e o *ReduceLROnPlateau* (reduzindo o *learning rate* pela metade após 5 épocas sem melhora na perda de validação), permitindo um ajuste mais fino na fase final do treino.

Sobre a normalização em lote. A arquitetura originalmente proposta incluía uma camada de *Batch Normalization* [?] após cada convolução. Na prática, entretanto, essa configuração fez o treinamento estagnar em acurácia equivalente ao acaso ($\approx 10\%$ para dez classes). O comportamento é consistente com uma limitação conhecida da técnica em cenários de poucos dados: as estatísticas móveis de média e variância, usadas na inferência, não convergem com o número reduzido de *batches* por época, de modo que a normalização aplicada na validação diverge da aplicada no treino. A remoção das camadas de *Batch Normalization*, mantendo o restante da arquitetura, foi suficiente para estabilizar o treinamento e alcançar os resultados reportados.

V. RESULTADOS

A Tabela ?? apresenta a acurácia global dos dois modelos desenvolvidos.

Em relação à abordagem tabular, o modelo MLP apresentou um treinamento estável e eficiente. A Figura ?? ilustra a queda acentuada da função de custo (*loss*) de treinamento e a ascensão da acurácia de validação, que atingiu seu ápice próximo à 20ª época (cerca de 70%). O mecanismo de *Early Stopping* interrompeu o treinamento em torno da 32ª época, garantindo que o modelo retivesse sua capacidade de generalização máxima antes de apresentar sobreajuste severo. A análise da Figura ?? reforça a precisão da rede: gêneros com assinaturas acústicas peculiares, como *classical* e *jazz*, foram amplamente reconhecidos, chegando a 100% de acertos no caso da música clássica. As maiores sobreposições ocorreram entre *hiphop* e *reggae* (4 falsos preditivos), e *rock* e *disco* (3 falsos preditivos), evidenciando a limitação dos MFCCs puros em discernir certos padrões rítmicos percussivos semelhantes.

A CNN atingiu 0,64 de acurácia na validação e 0,51 no teste. A Figura ?? apresenta as curvas de treinamento, nas quais se observam a convergência estável do modelo e um *overfitting* a partir da décima época, comportamento esperado dado o tamanho reduzido do conjunto de treino. A Figura ?? mostra a matriz de confusão na validação: o gênero *pop* foi o mais bem classificado (F1 de 0,93), seguido

de *classical* e *hiphop* (ambos com F1 de 0,80), enquanto *rock* e *country* concentraram os maiores erros (F1 de 0,32 e 0,50, respectivamente), refletindo a maior sobreposição de suas características com as dos demais gêneros.

Tabela I
ACURÁCIA NOS CONJUNTOS DE VALIDAÇÃO E TESTE

Modelo	Acurácia (val)	Acurácia (teste)
MLP	0.76	0.77
CNN	0.64	0.51




Figura 1. Curvas de perda (treino) e acurácia (validação) por época para o modelo tabular MLP.




Figura 2. Matriz de confusão do MLP no conjunto de validação.




Figura 3. Curvas de acurácia e perda por época da CNN (treino e validação).

VI. DISCUSSÃO

Os resultados indicam que o uso de descritores extraídos analiticamente (MFCCs) superou a extração autônoma




Figura 4. Matriz de confusão da CNN no conjunto de validação.

de atributos espaciais da CNN para a tarefa proposta e as restrições impostas pelo dataset. Como os coeficientes de Mel refletem intimamente a percepção auditiva humana da forma do envelope espectral (timbre geral da faixa), a rede MLP obteve excelentes desempenhos para separar gêneros com instrumentações fundamentais muito dissimilares (como clássico vs metal).

Por outro lado, a abordagem CNN sofreu uma restrição crítica: a quantidade de dados. Com apenas cerca de 700 espectrogramas para a fase de treinamento, a rede visual tendeu a se acomodar em *overfitting* precocemente, possuindo informações insuficientes para derivar generalizações universais complexas que descritores de base matemática (como o MFCC) já entregam mastigados para a rede. Ainda assim, é possível notar, por meio das matrizes de erro, que descritores exclusivamente espectrais do MLP podem confundir compassos baseados fortemente em *beats* sobrepostos (como a dificuldade entre *hiphop* e *reggae*), uma área temporal onde arquiteturas convolucionais alimentadas massivamente com dados poderiam se sobressair em trabalhos vindouros.

VII. CONCLUSÃO

Este trabalho comparou duas abordagens para classificação de gênero musical...

REFERÊNCIAS

- [1] TZANETAKIS, G.; COOK, P. Musical genre classification of audio signals. *IEEE Transactions on Speech and Audio Processing*, v. 10, n. 5, p. 293–302, 2002.
- [2] LOGAN, B. Mel Frequency Cepstral Coefficients for Music Modeling. In: *International Symposium on Music Information Retrieval (ISMIR)*, 2000.
- [3] COSTA, Y. M. G.; OLIVEIRA, L. S.; SILLA JR., C. N. An evaluation of convolutional neural networks for music classification using spectrograms. *Applied Soft Computing*, v. 52, p. 28–38, 2017.
- [4] IOFFE, S.; SZEGEDY, C. Batch normalization: Accelerating deep network training by reducing internal covariate shift. In: *International Conference on Machine Learning (ICML)*, 2015. p. 448–456.